

Reconocimiento de Actividades Humanas mediante video

Javier Ramírez¹

CICESE

`javier.ramirez@cicese.edu.mx`

Abstract. El reconocimiento de actividades humanas (HAR) a partir de vídeos es un área importante en visión por computadora con aplicaciones en vigilancia, salud y robótica. En este trabajo se comparan tres arquitecturas VJEPA2, VJEPA2.1 y un modelo baseline basado en ResNet18 con transformer temporal sobre un conjunto de datos de 11 clases de actividades cotidianas. Los resultados muestran que VJEPA2.1 alcanza una precisión del 92%, superando a VJEPA2 (37%) y al baseline (85%). Se analizan las diferencias arquitectónicas, el preprocesamiento requerido y el costo computacional.

Keywords: Reconocimiento de Actividades Humanas, VJEPA, Transformers

1 Introducción

El reconocimiento de actividades humanas (HAR) a partir de vídeos es una tarea fundamental en visión por computadora, con aplicaciones que abarcan desde la vigilancia inteligente y el cuidado de la salud hasta la robótica y la interacción humano-computadora [2]. A pesar de los avances recientes, el HAR sigue enfrentando desafíos derivados de la variabilidad de ángulos, oclusiones, fondos complejos y la alta dimensionalidad de los datos de vídeo [2]. Los enfoques tradicionales basados en el espacio de píxeles requieren grandes volúmenes de anotaciones y son sensibles a variaciones irrelevantes de la escena, lo que limita su capacidad de generalización.

En este contexto, la arquitectura predictiva de incrustación conjunta (JEPA), propuesta por Yann LeCun, ha surgido como una alternativa eficiente. A diferencia de los modelos generativos, JEPA aprende representaciones latentes abstractas, ignorando las partes impredecibles de la entrada y mejorando así la transferencia a tareas posteriores [1] [3].

2 Trabajo Relacionado

El reconocimiento de actividades humanas (HAR) basado en vídeo ha sido abordado tradicionalmente mediante arquitecturas que operan directamente en el espacio de píxeles. Bukht et al. [2] ofrecen una revisión de estos métodos, que

incluyen desde enfoques clásicos basados en características diseñadas manualmente hasta modelos profundos como redes convolucionales 3D (C3D, I3D), arquitecturas de dos flujos (espacial y temporal) y modelos híbridos que combinen CNNs para la extracción de características por fotograma con LSTMs para el modelado temporal. Estos métodos, aunque efectivos en ciertos escenarios, dependen fuertemente de grandes volúmenes de anotaciones y son sensibles a variaciones irrelevantes de la escena, como cambios de iluminación, oclusiones o fondos complejos, lo que limita su capacidad de generalización.

Posteriormente, los Transformers de vídeo, como TimeSformer y VideoMAE, introdujeron mecanismos de atención espacio-temporal que mejoraron el modelado de dependencias a largo plazo. Sin embargo, muchos de ellos aún operan en el espacio de píxeles y requieren un preentrenamiento en conjuntos de datos enormes para lograr un rendimiento competitivo.

En este contexto, Yann LeCun propuso la arquitectura predictiva de incrustación conjunta (JEPA), un paradigma de aprendizaje auto-supervisado que, en lugar de reconstruir píxeles, predice representaciones latentes abstractas de regiones enmascaradas del vídeo. Esta estrategia permite ignorar detalles impredecibles y resulta significativamente más eficiente [1]. La primera implementación de esta familia, V-JEPA 2, demostró ser capaz de capturar el movimiento global de acciones, entrenando un encoder para predecir tokens enmascarados a partir del contexto visible [1]. No obstante, sus representaciones locales resultaban ruidosas y fragmentadas, ya que la pérdida solo se aplicaba sobre los tokens ocultos, descuidando la coherencia espacial de las regiones visibles.

Para superar esta limitación, se desarrolló V-JEPA 2.1, que introduce dos mejoras. En primer lugar, la pérdida predictiva densa (Dense Predictive Loss) supervisa tanto los tokens visibles como los enmascarados, forzando al modelo a aprender una estructura espacial. En segundo lugar, la supervisión profunda (Deep Self-Supervision) aplica la pérdida en múltiples capas intermedias del encoder, mejorando el flujo de gradientes y la calidad de las representaciones jerárquicas. Además, V-JEPA 2.1 incorpora 3D-RoPE para codificar la posición relativa en el espacio-tiempo y SwiGLU para una mayor eficiencia en las capas feed-forward [3].

Esto permite que V-JEPA 2.1 combine un entendimiento global de la acción con características locales densas (geometría, profundidad, seguimiento preciso), lo que lo hace adecuado para tareas de reconocimiento de actividades cotidianas con un número limitado de ejemplos. El presente trabajo compara V-JEPA 2 y V-JEPA 2.1 en un conjunto de datos de 11 clases, con el fin de evaluar el impacto de estas mejoras en la precisión y la capacidad de generalización.

3 Metodología

3.1 Conjunto de datos

Se utilizó un conjunto de datos propio compuesto por vídeos de actividades humanas cotidianas, complementado con una colección pública disponible en

Kaggle [4]. Las clases finales fueron once: *Clapping*, *Handshake*, *Meet and Split*, *null*, *Picking Up Object*, *Placing Object*, *Sitting*, *Standing Still*, *Walking*, *Walking While Reading Book*, *Walking While Using Phone*. Inicialmente se recolectaron más de 100 vídeos por clase, pero por limitaciones de cómputo (GPU NVIDIA RTX 3060 de 12 GB) se redujo el conjunto a 40 vídeos para entrenamiento, 20 para validación y 40 para prueba por clase. Los vídeos tienen una duración promedio de 10 segundos y fueron grabados en diversas condiciones de iluminación, ángulo y fondo para aumentar la variabilidad.

Se realizó una limpieza manual eliminando vídeos con errores de codificación, duración atípica o contenido irrelevante. Posteriormente se balanceó el conjunto final para asegurar una representación equitativa de todas las clases en cada partición como se indica en la Tabla 1.

Table 1: Distribución de vídeos por clase.

Clase	Train	Val	Test
Clapping	40	20	40
Handshake	40	20	40
Meet and Split	40	20	40
null	40	20	40
Picking Up Object	40	20	40
Placing Object	40	20	40
Sitting	40	20	40
Standing Still	40	20	40
Walking	40	20	40
Walking While Reading Book	40	20	40
Walking While Using Phone	40	20	40

3.2 Preprocesamiento de vídeos

Para todos los modelos se aplicó un muestreo uniforme de 16 fotogramas por vídeo, cubriendo la totalidad de la duración (10s). VJEPA2 y VJEPA2.1 utilizaron sus propios procesadores internos para redimensionar y normalizar los fotogramas, sin aplicar aumentos de datos adicionales. En la implementación personalizada de VJEPA2.1, el dataset simplemente redimensiona cada fotograma a 224×224 píxeles y los convierte a tensor.

Para el modelo TemporalTransformer, el preprocesamiento fue distinto debido a las limitaciones computacionales. Entrenar un transformer desde cero sobre los vídeos originales habría requerido una cantidad masiva de datos y recursos, haciéndolo inviable. Por ello se optó por extraer características espaciales por fotograma usando una ResNet18 preentrenada en ImageNet. Este enfoque reduce la carga de entrenamiento, pero a costa de perder información temporal fina. Para hacer el proceso factible se redujo la resolución de los fotogramas a

112×112 píxeles. Las características extraídas (vectores de 512 dimensiones por fotograma) se almacenaron en disco, permitiendo entrenar el transformer sin reprocesar los vídeos en cada época.

3.3 Arquitecturas

VJEPa2 Se utilizó el modelo preentrenado `facebook/vjepa2-vitl-fpc64-256`. El backbone (encoder transformer) se mantuvo congelado durante el fine-tuning, entrenando únicamente la cabeza de clasificación. Esta cabeza está compuesta por un *pooler* basado en atención cruzada, que agrega la información temporal, seguido de una capa lineal de salida a 11 clases.

VJEPa2.1 Incorpora varias mejoras arquitectónicas. Utiliza un 3D patch embedding mediante convoluciones 3D y una atención con RoPE (Rotary Position Embedding) que separa las coordenadas espaciales y temporales para una mejor codificación de la posición. Emplea un MLP tipo SwiGLU con activación SiLU, más eficiente que las MLP estándar. Además, implementa salidas jerárquicas (deep self-supervision) que permiten supervisar múltiples capas del encoder, y una pérdida densa (Dense Predictive Loss) que supervisa tanto los tokens enmascarados como los visibles, junto con un context loss ponderado por distancia espacio-temporal.

Se utilizó el encoder preentrenado y se le añadió una cabeza de clasificación con mean pooling y dos capas lineales (512 neuronas y salida a 11 clases). El backbone se congeló durante el fine-tuning.

TemporalTransformer El modelo TemporalTransformer se diseñó como una alternativa ligera para comparar enfoques basados en transformers temporales sobre características extraídas por fotograma. Primero, se extrajeron características espaciales de cada vídeo utilizando una ResNet18 preentrenada en ImageNet, obteniendo para cada vídeo un tensor de forma (16, 512) (16 fotogramas, 512 dimensiones por fotograma). Estas características se almacenaron para evitar recomputarlas durante el entrenamiento.

El TemporalTransformer consta de una capa de posicional embedding (con máximo 32 posiciones), seguida de dos capas de transformer encoder con 8 cabezas de atención y una dimensión interna de 1024, se aplica un pooling temporal por promedio y una capa lineal de salida a 11 clases.

3.4 Costo computacional

El entrenamiento de VJEPa2.1 requirió aproximadamente 11 minutos por época (30 épocas totales) y consumió cerca de 5.5 GB de VRAM. VJEPa2 fue más ligero (3 GB VRAM) pero su rendimiento fue muy inferior. En cuanto al modelo TemporalTransformer, su costo principal no estuvo en el entrenamiento en sí, sino en la extracción de características mediante ResNet18, que requirió un preprocesamiento intensivo. El entrenamiento del transformer fue más rápido

que el de VJEPA2.1, pero a costa de reducir la resolución de los fotogramas (de 224×224 a 112×112), ya que de lo contrario el proceso se volvía inviable por el alto consumo de memoria y tiempo. Este preprocesamiento adicional representa una desventaja frente a VJEPA2.1, que trabaja directamente con los vídeos sin necesidad de extracciones externas de características.

4 Resultados Experimentales

4.1 Métricas de evaluación

Para evaluar el rendimiento de los modelos se utilizaron las métricas estándar en clasificación: precisión global (*accuracy*), precisión por clase, *recall*, puntuación F1 (macro y ponderada).

4.2 Resultados cuantitativos

La Tabla 2 resume el desempeño de los tres modelos evaluados sobre el conjunto de test (440 vídeos, 40 por clase). VJEPA2.1 supera a VJEPA2, alcanzando una precisión del 91.82%, mientras que VJEPA2 apenas logra un 37.27%, ligeramente por encima del azar (9.09%). El modelo TemporalTransformer, basado en características ResNet18 con transformer temporal, obtiene una precisión del 85.00%, situándose en un nivel intermedio.

Table 2: Comparación de métricas por clase en el conjunto de test.

Clase	VJEPA2.1			TemporalTransformer		
	Precisión	Recall	F1	Precisión	Recall	F1
Clapping	0.89	0.97	0.93	0.83	1.00	0.91
Meet and Split	0.81	0.85	0.83	0.83	0.85	0.84
Picking Up Object	1.00	1.00	1.00	0.95	1.00	0.98
Placing Object	1.00	1.00	1.00	1.00	1.00	1.00
Sitting	0.94	0.85	0.89	1.00	0.85	0.92
Standing Still	1.00	0.93	0.96	0.65	0.97	0.78
Walking	0.78	0.80	0.79	0.94	0.38	0.54
Walking While Reading Book	0.95	0.95	0.95	0.94	0.85	0.89
Walking While Using Phone	0.89	1.00	0.94	0.72	0.85	0.78
handshake	0.92	0.82	0.87	0.85	0.82	0.84
null	0.95	0.93	0.94	0.86	0.80	0.83
Macro avg	0.92	0.92	0.92	0.87	0.85	0.85

4.3 Matriz de confusión

Se observa que algunos de los errores ocurren entre acciones que comparten movimientos similares: *Meet and Split* se confunde con *Walking*. Estas confusiones son comprensibles dadas las similitudes semánticas y visuales.




Fig. 1: Matrices de confusión de los modelos evaluados en test.

5 Discusión

Los resultados experimentales muestran una diferencia significativa entre V-JEPA 2.1 (91.82% de precisión) y el modelo TemporalTransformer basado en ResNet18 (85.00%). Aunque el segundo alcanza una precisión aceptable, su comportamiento por clase muestra limitaciones estructurales importantes que explican la superioridad de V-JEPA.

En actividades que dependen fuertemente de la dinámica temporal, la diferencia entre ambos modelos es notable. Para la clase *Walking*, el Temporal Transformer obtiene un recall de solo 0.38, mientras que V-JEPA alcanza 0.80, lo que indica que el modelo basado en características por fotograma independiente no logra capturar adecuadamente el movimiento continuo, mientras que V-JEPA modela la estructura temporal de manera implícita. En la clase *Standing Still*, la precisión del Temporal Transformer es 0.65 frente a 1.00 de V-JEPA, mostrando que el primero confunde con frecuencia esta clase con otras actividades, mientras que V-JEPA separa claramente la ausencia de otras actividades. Finalmente, actividades sutiles como *Walking While Reading Book* y *Walking While Using Phone* también presentan mayor confusión en el Temporal Transformer, lo que evidencia su dependencia de información espacial sin un buen contexto temporal.

5.1 Limitaciones del enfoque basado en características estáticas

El pipeline del Temporal Transformer (ResNet18 preentrenado en ImageNet seguido de un transformer temporal) presenta un cuello de botella: las características extraídas por fotograma son puramente espaciales y no incorporan información de movimiento. Aunque el transformer intenta modelar la secuencia, la calidad de la representación de entrada limita su capacidad para capturar dinámicas complejas. Además, este enfoque es sensible al ruido visual (cambios de iluminación, fondos variables) porque opera directamente en el espacio de píxeles.

5.2 Ventajas de V-JEPA 2.1

Por el contrario, V-JEPA 2.1 aprende representaciones latentes que predicen la evolución del mundo sin necesidad de reconstruir píxeles. Esto le permite ignorar detalles irrelevantes y enfocarse en la estructura semántica del movimiento. Gracias a esta capacidad, generaliza mejor ante variaciones de iluminación, ángulo y fondo, como se observa en la alta precisión obtenida en clases como Standing Still y Placing Object. Además, puede manejar actividades con dinámicas largas, como Walking, porque la pérdida densa y la supervisión profunda mantienen la coherencia espaciotemporal a lo largo de la secuencia.

5.3 Implicaciones para el estado del arte

Los resultados confirman que las arquitecturas basadas en el principio JEPA, y en particular V-JEPA 2.1, representan un avance significativo sobre los enfoques clásicos de extracción de características por fotograma. Esto sugiere que modelar la estructura del mundo en el espacio latente es una dirección prometedora para el reconocimiento de actividades humanas, especialmente cuando se dispone de datos limitados y condiciones variables.

5.4 Limitaciones del estudio y trabajo futuro

A pesar de los buenos resultados, el conjunto de datos es relativamente pequeño (440 vídeos por clase) y las grabaciones son cortas (10s). Sería necesario validar V-JEPA 2.1 en *datasets* públicos más extensos (Kinetics-400, SSv2) para evaluar su escalabilidad y explorar la localización espaciotemporal de las actividades (detección de regiones de interés) y la integración del modelo en sistemas de tiempo real con optimizaciones como cuantización y podado.

6 Conclusiones

Se observó que el costo computacional crece demasiado al aumentar el número de vídeos o la resolución, lo que evidencia la necesidad de optimizaciones adicionales (podado de modelos mediante métodos de optimización) para hacer

viable su despliegue en entornos con recursos limitados. Sin embargo, las arquitecturas basadas en el principio JEPA parecen encaminarse a convertirse en el nuevo estado del arte, ya que requieren menos poder de cómputo que otros grandes modelos generativos o contrastivos y una ventaja enorme es que el vídeo puede utilizarse directamente sin necesidad de técnicas complejas de aumento o normalización. Además, muestran una notable adaptación a cambios en las condiciones lumínicas y de fondo, lo que las hace adecuadas para aplicaciones en entornos no controlados.

References

1. Assran, M., Bardes, A., Fan, D., Garrido, Q., Howes, R., Mojtaba, Komeili, Muckley, M., Rizvi, A., Roberts, C., Sinha, K., Zholus, A., Arnaud, S., Gejji, A., Martin, A., Hogan, F.R., Dugas, D., Bojanowski, P., Khalidov, V., Labetut, P., Massa, F., Szafraniec, M., Krishnakumar, K., Li, Y., Ma, X., Chandar, S., Meier, F., LeCun, Y., Rabbat, M., Ballas, N.: V-jepa 2: Self-supervised video models enable understanding, prediction and planning (2025), <https://arxiv.org/abs/2506.09985>
2. Bukht, T.F.N., Rahman, H., Shaheen, M., Algarni, A., Almujally, N.A., Jalal, A.: A review of video-based human activity recognition: theory, methods and applications. *Multimedia Tools and Applications* **84**, 18499–18545 (2024). <https://doi.org/10.1007/s11042-024-19711-w>, <https://doi.org/10.1007/s11042-024-19711-w>
3. Mur-Labadia, L., Muckley, M., Bar, A., Assran, M., Sinha, K., Rabbat, M., LeCun, Y., Ballas, N., Bardes, A.: V-jepa 2.1: Unlocking dense features in video self-supervised learning (2026), <https://arxiv.org/abs/2603.14482>
4. Rajput, S.M., Bilal, M., Habib, A.: Human activity recognition (har - video dataset) (2023). <https://doi.org/10.34740/KAGGLE/DSV/5722068>, <https://www.kaggle.com/dsv/5722068>